



Univerzitet u Nišu
Elektronski fakultet



SEMINARSKI RAD
IZ PREDMETA PRETRAŽIVANJE INFORMACIJA
Tema: Hibridni sistem za semantičku pretragu i rangiranje
akademske dokumenata

Mentor:

Prof. Suzana R. Stojković

Student:

Milan Mićović 19260

Niš, 2026. godine

SADRŽAJ

1. Uvod.....	3
2. Teorijske osnove pretraživanja informacija	4
2.1. Leksička pretraga i BM25 algoritam	4
2.2. Semantička pretraga i vektorski prostori (Embeddings).....	4
2.3. Hibridni pristup: Najbolje od obe strane.....	5
3. Specifičnosti obrade srpskog jezika	6
3.1. Problem morfološke varijabilnosti	6
3.2. Lematizacija pomoću Classla biblioteke	6
3.3. Značaj za BM25 algoritam.....	7
4. Arhitektura sistema.....	7
4.1. Indeksiranje na nivou stranice (Page-level Indexing)	7
4.2. Ekstrakcija i čišćenje sadržaja.....	8
4.3. Vektorska baza podataka i memorisanje (Persistence).....	8
5. Implementacija aplikacije (Korisnički interfejs)	8
5.1. Streamlit razvojno okruženje	9
5.2. Semantičko proširenje upita (Query Expansion)	9
5.3. Semantička ekstrakcija metapodataka	10
5.4. Dinamički prikaz PDF dokumenata (Preview)	11
5.5. Automatsko sažimanje stranica (AI Rezime).....	11
5.6. Preporuka srodnog sadržaja	12
6. Analitički moduli i vizuelizacija.....	13
6.1. Interaktivna mapa znanja (PCA vizuelizacija).....	13
6.2. Oblak reči (WordCloud) sa dinamičkim filtriranjem	13
6.3. Hibridno upoređivanje dokumenata	14
7. Rezultati i evaluacija sistema	16
7.1. Metodologija testiranja	16
7.2. Analiza rezultata benchmark testa.....	17
7.3. Interpretacija F1-score vrednosti.....	17
8. Zaključak.....	18
9. Literatura	19

1. Uvod


U savremenom akademskom i naučnom okruženju, količina dostupnih digitalnih informacija raste eksponencijalno. Tradicionalni sistemi za pretraživanje informacija (eng. Information Retrieval - IR), koji se oslanjaju isključivo na preklapanje ključnih reči, suočavaju se sa ozbiljnim ograničenjima. Glavni problemi ovakvih pristupa su nemogućnost razumevanja konteksta, sinonimije (različite reči sa istim značenjem) i polisemije (iste reči sa različitim značenjem), što često rezultira niskom preciznošću ili potpunim izostavljanjem relevantnih dokumenata.

Poseban izazov predstavlja pretraživanje dokumenata na srpskom jeziku, koji karakteriše bogata morfologija i složen sistem deklinacija.

Bez adekvatne lingvističke obrade, konvencionalni algoritmi poput TF-IDF ili BM25 ne mogu prepoznati da reči u različitim padežima pripadaju istom osnovnom pojmu.

Cilj projekta je prevazilaženje ograničenja klasične pretrage kombinovanjem dokazanih statističkih metoda (BM25) sa modernim tehnikama dubokog učenja i vektorskih reprezentacija (eng. embeddings).

Sistem je dizajniran da ne samo pronađe tražene termine, već da "razume" nameru korisnika i semantičku suštinu teksta. Pored samog pretraživanja, aplikacija nudi i napredne funkcionalnosti za analizu korpusa, kao što su vizuelizacija semantičkog prostora, automatsko sažimanje stranica i upoređivanje sličnosti naučnih radova. Kroz ovaj rad biće detaljno objašnjena arhitektura sistema, od faze indeksiranja i lematizacije, preko hibridnog rangiranja, do finalne evaluacije performansi sistema.



Slika 1: Konceptualna arhitektura hibridnog sistema koja kombinuje leksičku pretragu (Sparse) i semantičku pretragu (Dense).

2. Teorijske osnove pretraživanja informacija

Savremeni sistemi za pretraživanje informacija evoluirali su od prostog poređenja karaktera ka dubokom razumevanju prirodnog jezika. Da bi se postigla maksimalna efikasnost, ovaj projekat koristi hibridni model koji kombinuje leksičke (statističke) i semantičke (neuronske) metode.

2.1. Leksička pretraga i BM25 algoritam

Leksička pretraga se zasniva na prisustvu konkretnih reči iz upita u dokumentu. Standard u ovoj oblasti je algoritam **BM25** (Best Matching 25), koji predstavlja usavršenu varijantu klasične TF-IDF metode.

BM25 meri relevantnost dokumenta na osnovu dva glavna faktora:

Term Frequency (TF): Koliko puta se reč pojavljuje u dokumentu. Međutim, BM25 koristi "saturaciju", što znači da nakon određenog broja ponavljanja, dodatno pojavljivanje iste reči ne povećava značajno ocenu dokumenta.

Inverse Document Frequency (IDF): Reči koje su retke u celoj bazi (npr. "metabolomika") nose mnogo veću težinu od čestih reči (npr. "sistem").

Ključna prednost BM25 algoritma je normalizacija dužine, koja sprečava da duži dokumenti budu nepravedno favorizovani samo zato što sadrže više reči.

2.2. Semantička pretraga i vektorski prostori (Embeddings)

Dok se leksička pretraga bavi slovima, semantička pretraga se bavi smislom. Osnova ovog pristupa su vektorski embeddings. To su numeričke reprezentacije teksta gde se rečenice ili pasusi mapiraju u višedimenzionalni prostor.


U ovom projektu korišćen je **Multilingual-E5 (small)** model. Proces funkcioniše na sledeći način:

Tekst se provlači kroz duboku neuronsku mrežu (Transformer arhitektura).

Izlaz je vektor fiksne dužine od 384 dimenzije.

Značenje teksta je kodirano u ovim brojevima. U vektorskom prostoru, rečenice sa sličnim značenjem će se nalaziti blizu jedna drugoj, čak i ako ne dele nijednu zajedničku reč. Sličnost se meri kosinusnom sličnošću (ugao između dva vektora).

Semantička pretraga u vektorskom prostoru



Slika 2: Geometrijska reprezentacija dokumenata u vektorskom prostoru.

2.3. Hibridni pristup: Najbolje od obe strane

Samostalne metode imaju svoje mane. Leksička pretraga pati od problema sinonimije (ne nalazi "trauma" ako tražite "povreda"), dok semantička pretraga nekada može biti previše apstraktna i promašiti tačne nazive ili šifre.

Hibridni pristup spaja ove dve metode:

BM25 osigurava da dokumenti koji sadrže tačne stručne termine budu visoko rangirani.

Vektorski E5 model omogućava pronalaženje dokumenata na osnovu šireg konteksta i istraživačkog pitanja.

Kombinovanjem ovih rezultata (tzv. Rank Fusion), dobijamo sistem koji je robustan, precizan i sposoban da odgovori na kompleksne korisničke zahteve koje tradicionalni pretraživači ne mogu da obrade.

3. Specifičnosti obrade srpskog jezika

Pretraživanje informacija na srpskom jeziku predstavlja značajno veći izazov u odnosu na engleski jezik zbog bogate morfologije i razvijenog sistema fleksije. Reči u srpskom jeziku menjaju svoj oblik kroz padeže, brojeve i rodove, što direktno utiče na preciznost i odziv (recall) sistema za pretragu.

3.1. Problem morfološke varijabilnosti

Tradicionalni algoritmi za pretragu tretiraju svaku varijaciju reči kao potpuno različit pojam. Na primer, reči "student", "studenta", "studentu" i "studentima" imaju istu semantičku osnovu, ali bi ih klasičan BM25 algoritam bez prethodne obrade indeksirao kao četiri nezavisna termina. To bi značilo da korisnik koji pretražuje termin "student" ne bi dobio rezultate koji sadrže reč "studentima", što drastično smanjuje efikasnost pretrage u akademskim dokumentima.

3.2. Lematizacija pomoću Classla biblioteke

Da bi se ovaj problem rešio, u radu je primenjen proces lematizacije.

Lematizacija je postupak svođenja reči na njen osnovni, kanonski oblik.

Za ovu svrhu korišćena je biblioteka **Classla**, koja predstavlja trenutno najnapredniji alat za obradu južnoslovenskih jezika zasnovan na dubokim neuronskim mrežama.

Proces obrade obuhvata:

1.Tokenizaciju: Razbijanje teksta na pojedinačne reči.

2.POS Tagging: Određivanje vrste reči (imenica, glagol, pridev).

3.Lematizaciju: Transformaciju reči u osnovni oblik (npr. "učimo" → "učiti", "znanjima" → "znanje").

Original	Studenti istražuju nove metode u laboratorijama.
Lematizovano	student istraživati nov metoda u laboratorija.

Slika 3: Primer procesa lematizacije teksta na srpskom jeziku

```
def lematizuj_tekst(tekst):  
    doc = nlp(tekst)  
    return " ".join([word.lemma.lower() for sent in doc.sentences for word in sent.words if word.lemma])
```

Slika 4: Implementacija procesa lematizacije korišćenjem neuronskog modela biblioteke Classla

3.3. Značaj za BM25 algoritam

Lematizacija je kritična komponenta za ispravno funkcionisanje leksičke pretrage. Pre kreiranja BM25 indeksa, kompletan tekstualni sadržaj svih PDF dokumenata je lematizovan. Time je vokabular "normalizovan", što omogućava algoritmu da precizno računa učestalost termina (Term Frequency). Na ovaj način, sistem obezbeđuje visoku preciznost jer upit "povreda" ispravno pogađa dokument u kojem se pominju "povredama" ili "povredu".

4. Arhitektura sistema

Arhitektura sistema je dizajnirana tako da omogući efikasno procesiranje akademskih dokumenata velikog obima. Sistem se sastoji iz tri glavne faze: indeksiranje stranica, generisanje embeddinga i hibridno pretraživanje.

4.1. Indeksiranje na nivou stranice (Page-level Indexing)

Za razliku od pretrage celih dokumenata, ovaj sistem koristi granularnost(chunks) na nivou stranice. To znači da se svaka stranica PDF dokumenta tretira kao zaseban zapis u bazi podataka. Ovakav pristup omogućava:

Preciznije rangiranje: AI model dobija manju količinu teksta, što sprečava "uprosečavanje" smisla dokumenta.

Direktan preview: Sistem može korisnika poslati direktno na tačnu stranicu gde se nalazi odgovor.

4.2. Ekstrakcija i čišćenje sadržaja

Proces počinje upotrebom biblioteke **PyMuPDF (fitz)** koja vrši ekstrakciju sirovog teksta iz PDF fajlova. Nakon ekstrakcije, tekst se podvrgava čišćenju i lematizaciji, a zatim se kreira hibridna struktura podataka koja sadrži originalni tekst, lematizovanu verziju za BM25 i metapodatke o fajlu (ime, putanja, strana).

```

nlp = classla.Pipeline('sr', processors='tokenize,pos,lemma')

def učitaj_i_lematizuj_pdfove(folder_putanja):
    dokumenti = []

    for fajl in os.listdir(folder_putanja):
        if fajl.endswith(".pdf"):
            putanja = os.path.join(folder_putanja, fajl)
            print(f"Obradujem: {fajl}")

            doc = fitz.open(putanja)
            pun_tekst = ""
            for strana in doc:
                pun_tekst += strana.get_text()

            # Lematizacija
            obradjen_doc = nlp(pun_tekst)
            lematizovan_tekst = " ".join([word.lemma.lower() for sent in obradjen_doc.sentences for word in sent.words])

            dokumenti.append({
                "ime_fajla": fajl,
                "originalni_tekst": pun_tekst,
                "lematizovan_tekst": lematizovan_tekst
            })

    return dokumenti

```

Slika 5: Implementacija procesa učitavanja i masovne obrade PDF dokumenata.

4.3. Vektorska baza podataka i memorisanje (Persistence)

Pošto su procesi lematizacije i generisanja embeddinga računski zahtevni, sistem koristi mehanizam trajnog skladištenja (persistence). Obradeni podaci se serijalizuju u .pkl (Pickle) format. Pri svakom narednom pokretanju, sistem prvo proverava postojanje indeksa, što omogućava da pretraga radi trenutno, bez potrebe za ponovnom AI analizom celog korpusa.


5. Implementacija aplikacije (Korisnički interfejs)

Korisnički interfejs (UI) dizajniran je kao veb-aplikacija koja omogućava istraživačima laku interakciju sa hibridnim motorom za pretragu. Glavni akcenat je stavljen na brzinu odziva, preglednost metapodataka i interaktivnu vizuelizaciju.

5.1. Streamlit razvojno okruženje

Za razvoj interfejsa izabran je okvir Streamlit. Razlozi za ovaj izbor su višestruki:

1. **Reaktivnost:** Streamlit omogućava trenutno osvežavanje komponenti pri svakoj promeni upita ili filtera.
2. **Integracija sa AI stack-om:** Savršeno se uklapa sa bibliotekama kao što su PyTorch i Plotly.
3. **Modularnost:** Korišćenjem tabova(st.tabs) i bočnog panela(st.sidebar), postignuta je jasna separacija između pretrage, analitike i evaluacije.



Slika 6: Glavni interfejs aplikacije sa rezultatima hibridne pretrage.


5.2. Semantičko proširenje upita (Query Expansion)

Jedan od ključnih izazova u pretraživanju akademskih dokumenata je razlika između terminologije koju koristi korisnik i specifičnog naučnog rečnika u dokumentima. Kako bi se ovaj problem prevazišao, implementiran je modul za semantičko proširenje upita.

Sistem ne koristi proste rečnike sinonima, već se oslanja na vektorsku bliskost. Kada korisnik unese upit, sistem ga pretvara u vektor i poredi sa svim prethodno izvučenim ključnim rečima (tagovima) iz celokupne baze dokumenata.

Aplikacija korisniku ispisuje poruku "Možda vas zanima i:" sa listom pojmova koji su semantički najbliži njegovom upitu.

Na primer, za upit "lečenje", sistem može predložiti termine kao što su "farmacija" ili "terapija", čime usmerava korisnika ka preciznijim naučnim rezultatima.



Slika 7: Vizuelni prikaz proširenja upita na osnovu semantičke sličnosti sa pojmovima iz korpusa.


5.3. Semantička ekstrakcija metapodataka

Jedna od najnaprednijih funkcija aplikacije je automatska identifikacija naslova i autora rada kao i godinu kada je rad urađen.

Umesto klasičnih pravila, implementiran je **Zero-shot Semantički Ekstraktor**.

Logika: Sistem uzima kandidate sa prve strane dokumenta i vrši njihovo hibridno rangiranje. Rang se računa kombinovanjem semantičke bliskosti (da li tekst zvuči kao naslov ili ime) i vizuelne važnosti (relativna veličina fonta u odnosu na ostatak strane).

Batch obrada: Kako bi se očuvale performanse, ovi metapodaci se generišu grupno prilikom indeksiranja, čime se drastično skraćuje vreme pretrage u realnom vremenu.




Slika 8: Rezultat automatske ekstrakcije metapodataka za potrebe citiranja.

5.4. Dinamički prikaz PDF dokumenata (Preview)

Izazov ugrađivanja PDF dokumenata od više stotina megabajta u veb-pretraživač rešen je metodom dinamičke ekstrakcije stranica.

Kada korisnik klikne na dugme "Pregled", sistem pomoću biblioteke fitz vrši "sečenje" samo one stranice na kojoj je pronađen relevantan sadržaj. Ta stranica se u deliću sekunde pretvara u privremeni PDF bajt-strim i šalje u browser. Ovim pristupom se izbegava preopterećenje RAM memorije, omogućavajući trenutni uvid u kontekst pronađene informacije.

Obezbeđena je i mogućnost preuzimanja kompletnog pdf dokumenta.




Slika 9: Prikaz nađene pdf stranice

5.5. Automatsko sažimanje stranica (AI Rezime)

Kako bi se korisniku olakšalo brzo skeniranje relevantnih informacija, implementirana je metoda za automatsko generisanje rezimea stranice. Za razliku od sporih generativnih modela, ovde je primenjena metoda ekstraktivnog sažimanja zasnovanog na centroidu (eng. Centroid-based summarization).

Tehnika: Sistem deli tekst stranice na rečenice i svaku od njih pretvara u vektor. Zatim se računa "prosečan smisao" cele stranice (centroid).

Rezultat: AI bira tri rečenice koje su semantički najbliže tom centroidu. Na ovaj način korisnik dobija najreprezentativniji deo teksta bez potrebe za eksternim API pozivima ili dodatnim trošenjem resursa.




Slika 10: Prikaz automatski generisanog rezimea za selektovanu stranicu.

5.6. Preporuka srodnog sadržaja

Funkcionalnost **"Slično"** pretvara klasičan pretraživač u napredni sistem za preporuku. Ova opcija omogućava korisniku da, nakon što pronađe bitnu informaciju, jednim klikom identifikuje srodne teme u celom korpusu dokumenata.

- Vektorska korelacija: Sistem uzima embedding (vektor) trenutno pregledane stranice i vrši brzu kalkulaciju kosinusne sličnosti sa svim ostalim stranicama u bazi podataka.
- Cross-document analiza: Rezultat pretrage može biti stranica iz potpuno drugog dokumenta (npr. pronalaženje veze između prava i medicine), što je ključno za multidisciplinarna istraživanja.



Slika 11: Identifikacija semantički srodnih stranica unutar celokupnog korpusa.

6. Analitički moduli i vizuelizacija


Osim same pretrage, sistem nudi napredne module za analizu celokupnog korpusa dokumenata. Ovi moduli omogućavaju uočavanje skrivene veze između dokumenata i pružaju globalnu sliku o temama koje dominiraju u bazi.

6.1. Interaktivna mapa znanja (PCA vizuelizacija)

AI model E5 generiše vektore od 384 dimenzije, što je nemoguće vizuelno predstaviti. Kako bi se korisniku omogućio uvid u strukturu znanja, primenjena je metoda analize glavnih komponenti (eng. Principal Component Analysis - PCA).

PCA algoritam vrši redukciju dimenzionalnosti, svodeći 384 dimenzije na dve (X i Y ose), uz maksimalno očuvanje varijanse i odnosa između podataka.

Na interaktivnom grafikonu, svaka tačka predstavlja jednu stranicu PDF dokumenta. Stranice koje se bave sličnim temama prirodno formiraju "oblake" ili klastere. Na primer, sve stranice iz oblasti medicine biće grupisane u jednom delu prostora, dok će pravo biti u drugom, što jasno dokazuje sposobnost sistema da razume semantičku strukturu korpusa.



Slika 12: Vizuelna reprezentacija semantičkog prostora svih indeksiranih stranica.


6.2. Oblak reči (WordCloud) sa dinamičkim filtriranjem

Kao dopuna mapi znanja, implementiran je WordCloud prikaz koji vizuelno ističe najznačajnije pojmove u bazi. Kako bi se osigurala čistoća prikaza, razvijen je sistem za dinamičku eliminaciju šuma:

- Sistem automatski prepoznaje imena autora iz metapodataka i dodaje ih u listu stop-reči.

- Time WordCloud prikazuje isključivo suštinske naučne koncepte, omogućavajući korisniku da odmah shvati primarnu namenu celokupne "biblioteke".

Slika 13: Stop reči



Zbog toga je uveden hibridni model poređenja:

Semantička komponenta (40%): meri bliskost "prosečnog smisla" dokumenata (centroidi).

Leksička komponenta (60%): koristi Jaccardov indeks za merenje preklapanja ključnih naučnih pojmova.

Ovakva kombinacija osigurava da se visoka sličnost dobije samo ako radovi dele i sličan kontekst i specifičnu terminologiju.

Threshold za sličnost je 30%, ukoliko je sličnost manja od toga, onda su radovi iz različitih oblasti.

```
def uporedi_dokumente(ime1, ime2, baza):
    import torch

    emb1 = torch.stack([d['embedding'] for d in baza if d['ime'] == ime1])
    emb2 = torch.stack([d['embedding'] for d in baza if d['ime'] == ime2])

    cent1 = torch.mean(emb1, dim=0, keepdim=True)
    cent2 = torch.mean(emb2, dim=0, keepdim=True)

    semanticka_slicnost = util.cos_sim(cent1, cent2).item()
    sem_score = max(0, (semanticka_slicnost - 0.7) / 0.3)

    tagovi1 = set()
    for d in baza:
        if d['ime'] == ime1:
            tagovi1.update(d.get('kljucne_reci', []))


    tagovi2 = set()
    for d in baza:
        if d['ime'] == ime2:
            tagovi2.update(d.get('kljucne_reci', []))

    if not tagovi1 or not tagovi2:
        leksicka_slicnost = 0
    else:
        presek = tagovi1.intersection(tagovi2)
        unija = tagovi1.union(tagovi2)
        leksicka_slicnost = len(presek) / len(unija)


    finalni_score = (sem_score * 0.4) + (leksicka_slicnost * 0.6)

    zajednicke = list(tagovi1.intersection(tagovi2))
    return finalni_score * 100, zajednicke
```

Slika 15: Implementacija



Slika 16: Rezultati poređenja (Umerena sličnost)



Slika 17: Rezultati poređenja (Potpuno različite oblasti)

7. Rezultati i evaluacija sistema

Ključni korak u razvoju svakog sistema za pretraživanje informacija je objektivno merenje njegovih performansi.

U tu svrhu implementiran je poseban modul za evaluaciju koji testira sposobnost hibridnog motora da pronađe relevantne dokumente na osnovu skupa kontrolnih pitanja.

7.1. Metodologija testiranja


Za potrebe evaluacije definisan je testni skup od četiri specifična istraživačka upita, po jedan za svaku naučnu oblast prisutnu u bazi (Fizika, Hemija, Medicina, Pravo). Cilj je bio proveriti da li sistem ispravno rangira primarni dokument na prvu poziciju, čak i kada su upiti formulisani korišćenjem stručne terminologije.

Sistem je meren kroz dve ključne metrike:

- Precision@1 (Preciznost na prvoj poziciji): Procenat upita za koje je sistem vratio tačan dokument kao prvi rezultat. Ovo je mera "autoritativnosti" pretraživača.
- Recall@3 (Odziv u prvih tri): Mera koja pokazuje koliko često se tačan dokument nalazi unutar top 3 rezultata, što je prihvatljivo odstupanje u realnim scenarijima.

7.2. Analiza rezultata benchmark testa

Nakon pokretanja automatizovanog testa, dobijeni su rezultati koji potvrđuju visoku efikasnost hibridnog pristupa.



Slika 18: Rezultati automatizovanog benchmark testa sa prikazom preciznosti i odziva.

Sistem je postigao visoke vrednosti metrika (često 1.00 za oba parametra), što ukazuje na to da kombinacija BM25 leksičkog podudaranja i E5 semantičkih vektora eliminiše greške koje bi se javile kod pojedinačnih modela.

Na primer, leksička komponenta "zakucava" tačne termine, dok semantička komponenta omogućava da upit formulisan kao pitanje ispravno mapira smisao na relevantnu stranicu disertacije.

7.3. Interpretacija F1-score vrednosti

Izračunati F1-score predstavlja harmonijsku sredinu preciznosti i odziva. Stabilno visoke vrednosti ovog parametra u testu dokazuju da sistem nije samo slučajan "pogodak" ključnih reči, već da robusno procesira akademski tekst na srpskom jeziku, zahvaljujući prethodno izvršenoj lematizaciji i dubokom razumevanju konteksta.

Matematički posmatrano, F1-score se definiše kao harmonijska sredina preciznosti i odziva:

$$F1 = 2 * \frac{Precision * Recall}{Precision + Recall}$$

U kontekstu ovog projekta, F1-score nam služi kao jedinstveni indikator kvaliteta pretrage. Visoka vrednost ovog parametra u sprovedenim testovima potvrđuje da hibridni sistem uspešno balansira između leksičke strogosti (da ne vraća nebitne rezultate) i semantičke širine (da ne propusti relevantne radove zbog drugačije terminologije).

8. Zaključak

Razvoj hibridnog sistema za semantičku pretragu akademskih dokumenata pokazao je da integracija tradicionalnih statističkih algoritama i modernih neuronskih mreža pruža superiorne rezultate u poređenju sa konvencionalnim metodama pretraživanja.

Kroz implementaciju ovog projekta, uspešno su rešeni ključni izazovi obrade informacija na srpskom jeziku, pre svega putem neuronske lematizacije koja je omogućila precizno indeksiranje uprkos složenoj morfologiji jezika.

Glavni doprinosi ovog rada ogledaju se u sledećem:

1. Semantičko razumevanje: Upotreba Multilingual-E5 (small) modela omogućila je pronalaženje dokumenata na osnovu značenja i konteksta, čime je prevaziđen jaz sinonimije.
2. Hibridno rangiranje: Kombinovanjem BM25 i vektorskih embeddinga postignut je balans između leksičke tačnosti i širine konteksta.
3. Interaktivna analitika: Vizuelizacija semantičkog prostora pomoću PCA algoritma i automatska ekstrakcija metapodataka omogućili su pregledan i razumljiv rad sa samom aplikacijom.

Praktična evaluacija potvrdila je visoku preciznost sistema, sa stabilnim Precision i Recall vrednostima nad testnim skupom akademskih dokumenata. Iako je sistem trenutno optimizovan za rad sa manjim korpusom u .pkl formatu, arhitektura je postavljena tako da se u budućnosti može lako nadograditi namenskim vektorskim bazama podataka (poput FAISS-a) za rad sa hiljadama dokumenata.

Zaključno, ovaj projekat predstavlja funkcionalnu osnovu za napredne bibliotečke sisteme i digitalne repozitorijume naučnog sadržaja.

9. Literatura

1. Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press.
2. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. HuggingFace - Sentence Transformers.
3. Ljubešić, N., & Dobrovoljc, K. (2019). What a Difference a Context Makes: The Case of Serbian and Croatian Lemmatization. Classla Library documentation.
4. Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., & Wei, F. (2022). Text Embeddings by Weakly-Supervised Contrastive Pre-training (E5 model paper).
5. Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval.
6. Streamlit Documentation: <https://docs.streamlit.io/>
7. PyMuPDF (fitz) Documentation: <https://pymupdf.readthedocs.io/>